Sistema de Gestión del Conocimiento de Softtek

Caso de estudio: Softtek · Ciclo de vida, ontología, clasificación automática y búsqueda semántica · Avance del proyecto, octubre 2026



Softtek: empresa mexicana de TI fundada en 1982 en Monterrey

Tipo de organización

Empresa privada de servicios y consultoría de TI; ~15,000 empleados, 30 oficinas; pionera del modelo Nearshore

Actividades principales

- Desarrollo ágil y modernización de aplicaciones
- QA, DevOps e ingeniería de confiabilidad (SRE)
- Servicios SAP y Salesforce
- Gestión de aplicaciones, nube y soporte a usuarios
- Consultoría digital y automatización cognitiva

Fuente: Softtek Fast Facts 2024 y Wikipedia. Documentos y resultados ilustrativos.

CONOCIMIENTO QUE MANEJA: 5 TIPOS DE DOCUMENTO

Documentación técnica
Referencias de API, arquitectura, guías de despliegue

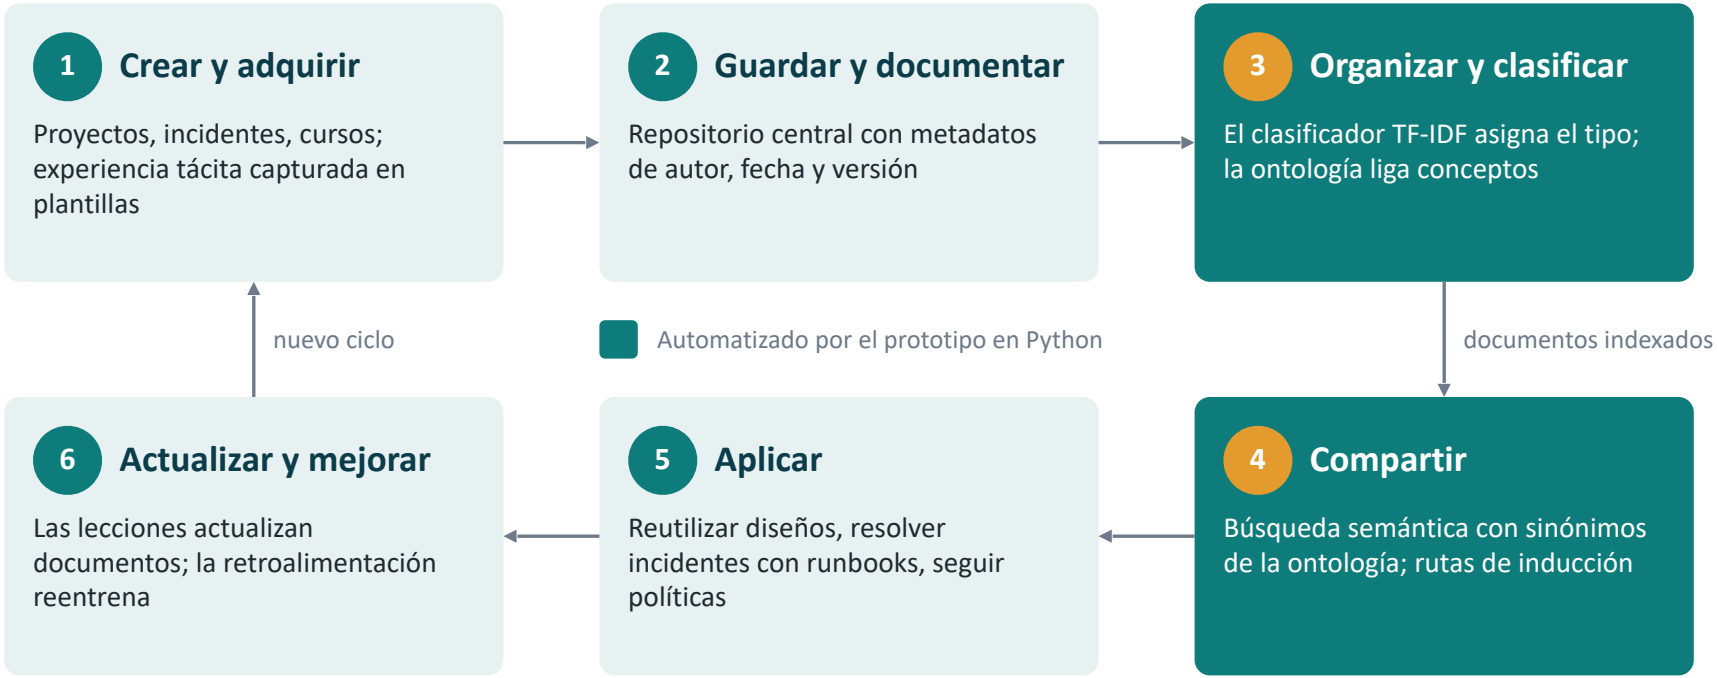
Políticas y procedimientos
Seguridad, home office, viáticos, control de cambios

Reportes de proyecto
Reportes de avance, revisiones de sprint, lecciones

Manuales de capacitación
Guías de inducción, cursos, tutoriales

Reportes de incidentes
Post-mortems, análisis de causa raíz

El conocimiento recorre un ciclo cerrado de seis etapas



La ontología liga cada tipo de documento a un concepto



Archivo OWL/SKOS ontology/softtek_ontology.ttl · 13 clases del dominio, 5 clases de documento, 22 relaciones, 372 tripletas

Las relaciones tipadas hacen consultable el grafo

Propiedad	De → A	Ejemplo
describes	Doc. técnica → Sistema	TD01 → API de pagos
governs	Política → Proceso	PP07 → Gestión de cambios
reportsOn	Reporte proy. → Proyecto	PR10 → Banca móvil
teaches	Manual → Habilidad	TM03 → Operar Kubernetes
documents	Rep. incidente → Incidente	IR01 → Caída de pagos
references	Documento → Documento	IR01 → TD01
updates	Lección → Documento	Prueba de rendim. → TD04, PP07



Pregunta de competencia

¿Qué documentos deben actualizarse después de los incidentes?

Caída de la API de pagos
→ Guía de logs y monitoreo (TD07)

Degradación de la BD de inventario
→ Esquema de base de datos (TD04)
→ Gestión de cambios (PP07)

Respondida por exercises/ex6_ontology_queries.py

El clasificador asigna el tipo de documento en cuatro pasos

1. Cargar

60 documentos de ejemplo etiquetados, 12 por categoría

2. Preprocesar

Minúsculas, quitar stop words, stemming de Porter

3. TF-IDF

Unigramas + bigramas, tf sublineal: ~2,180 términos

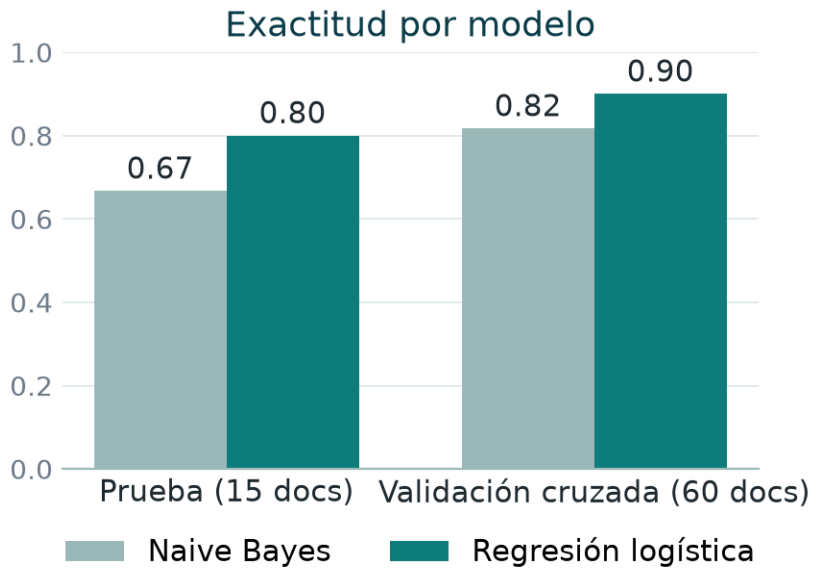
4. Entrenar y clasificar

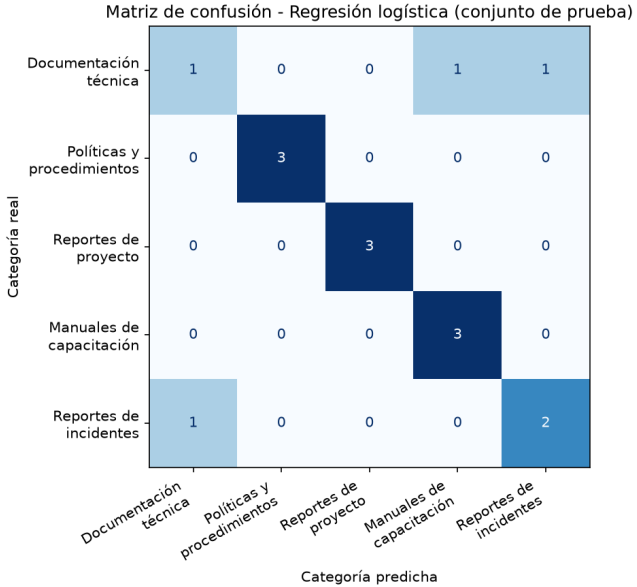
Naive Bayes vs Regresión logística; categoría + confianza

Peso TF-IDF: $\text{tfidf}(t, d) = (1 + \ln \text{tf}_{t,d}) \times (\ln((1 + N) / (1 + \text{df}_t)) + 1)$; luego cada vector se normaliza con L2

Ejecutar: `python src/classifier.py` | `python src/classifier.py --text "..."`

La regresión logística clasifica con 0.90 de exactitud





La prueba tiene 3 docs por clase: un error mueve la exactitud 0.07. La validación cruzada es la cifra confiable.

Los errores solo ocurren entre Documentación técnica y Reportes de incidentes, que comparten palabras como API, service, deploy.

Cinco de seis documentos nuevos se clasificaron correctamente

Id	Texto (inicio)	Predicción	Conf.	¿Bien?
N01	The checkout service was down for 25 minutes after a certificate expired…	Reportes de incidentes	0.61	Sí
N02	Employees must lock their screen when leaving the desk…	Políticas y procedimientos	0.32	Sí
N03	The search service exposes a GET /v1/search endpoint…	Documentación técnica	0.49	Sí
N04	Module 3 of the course teaches how to write SQL queries…	Manuales de capacitación	0.69	Sí
N05	The project is two weeks behind schedule; budget spent is 70%…	Reportes de proyecto	0.76	Sí
N06	New team members should complete the onboarding lessons on Docker…	Reportes de proyecto	0.34	No



N06 debería ser Manual de capacitación: "team" y "client project" son términos fuertes de Reportes de proyecto. Las predicciones con confianza menor a 0.40 podrían pasar a revisión humana.

La búsqueda ordena documentos por similitud coseno

1

Consulta en lenguaje natural

"what happened when the payment system went down"

2

Expansión con ontología

El altLabel SKOS "went down" agrega "outage incident"

3

Vector TF-IDF

Mismo vectorizador ajustado a los documentos

4

Similitud coseno

Puntaje contra los 60 vectores de documentos

5

Top-k resultados

IR01 (caída de la API de pagos) queda en 1.er lugar (0.197)

cos(q, d) = (q · d) / (||q|| ||d||)

1 = misma distribución de términos, 0 = ningún término en común. Ejecutar: `python src/semantic_search.py --demo`

Stemming y ontología ponen primero el documento correcto

Consulta: "what happened when the payment system went down"

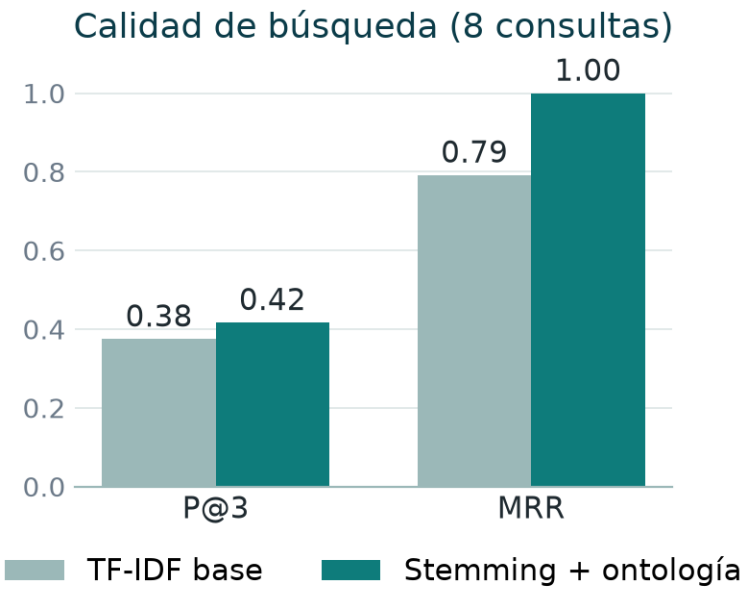
TF-IDF simple (base)

1. IR10 Post-mortem de cache stampede (0.103)
2. PR01 Reporte de avance plataforma retail (0.098)

IR01 no aparece: dice "Payments" y "Outage"

Stemming + expansión con ontología

1. IR01 Post-mortem: caída de la API de pagos (0.197)
2. IR11 Caída del servicio de correo (0.195)
3. IR04 Falla de red del centro de datos (0.168)



MRR 1.00: un documento relevante queda primero en todas las consultas de prueba.

Seis ejercicios de los Temas 1–6 construyeron el prototipo

1. Preprocesamiento

Vocabulario de 986 palabras → 704 raíces (29% menor)

2. TF-IDF a mano

Los valores manuales coinciden con scikit-learn

3. Similitud coseno

Docs del mismo tipo 2–5× más similares que entre tipos

4. Pruebas de clasificación

4 representaciones × 3 modelos; mejor exactitud 0.90

5. Evaluación de búsqueda

8 consultas evaluadas: MRR 0.79 → 1.00

6. Consultas a la ontología

5 preguntas SPARQL sobre 372 tripletas

Las técnicas básicas ya cubren el núcleo del KMS

TF-IDF + regresión logística clasifica con 0.90; la búsqueda con ontología pone primero un documento relevante en todas las consultas de prueba

Siguientes pasos

- Ampliar la colección a más de 60 documentos
- Enviar predicciones de baja confianza a revisión humana
- Agregar embeddings para búsqueda por significado
- Ligar documentos nuevos a la ontología en automático